

LAPORAN TEKNIS CAPSTONE PROJECT
PEMBELAJARAN MESIIN

***PREDIKSI RISIKO PENYAKIT JANTUNG MENGGUNAKAN MACHINE
LEARNING***

Dosen Pengampu:
Abu Salam M.Kom



Disusun oleh:
Laily Muthia Nabilmanan **A11.2024.15618**

PROGRAM STUDI SARJANA TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO SEMARANG
2026

DAFTAR ISI

COVER

DAFTAR ISI

BAB I

PENDAHULUAN	4
1.1 Latar Belakang	4
1.2 Tujuan Bisnis/Analisis dan Metrik Kesuksesan	5
1.3 Sumber dan Dokumentasi Dataset	5
1.4 Statistik Deskriptif Awal	7

BAB II

METODOLOGI (CRISP-DM)	9
2.1 Business Understanding	9
2.2 Data Understanding (Exploratory Data Analysis)	9
2.2.1 Analisis Kualitas Data	10
2.2.2 Analisis Univariat	10
2.2.3 Analisis Multivariat	12
2.2.4 Visualisasi 5 Insight Kunci	13
2.3 Data Preparation (Feature Engineering & Preprocessing)	15
2.4 Pembagian Dataset (Train-Validation-Test Split)	16
2.5 Modelling	17
2.6 Evaluation	18
2.7 Deployment	19

BAB III

HASIL DAN ANALISIS	20
3.1 Hasil Tuning Hyperparameter	20
3.2 Perbandingan Performa Model (Data Uji)	21
3.3 Interpretasi Model Terbaik (XGBoost)	22
3.4 Aplikasi Deployment	23

BAB IV

KESIMPULAN DAN REKOMENDASI	26
4.1 Kesimpulan	26
4.2 Keterbatasan Penelitian	26
4.3 Rekomendasi	27

BAB IV

KESIMPULAN DAN REKOMENDASI	26
4.1 Kesimpulan	26

4.2 Keterbatasan Penelitian.....	26
4.3Rekomendasi.....	27
BAB IV	
DOKUMENTASI DAN PRESENTASI	26
5.1Link GitHub	26
5.2 Link Streamlit (Demo).....	26
5.3Link YouTube (Presentasi).....	27
5.4Link Laporan PDF	27

BAB I

PENDAHULUAN

1.1 Latar Belakang

Penyakit kardiovaskular merupakan salah satu penyebab kematian tertinggi di dunia. Menurut World Health Organization (WHO), jutaan orang meninggal setiap tahunnya akibat penyakit ini. Padahal, sebagian besar kasus penyakit jantung dapat dicegah apabila faktor risikonya dapat diketahui sejak dini. Namun, proses diagnosis seperti angiografi koroner masih bersifat invasif, membutuhkan biaya yang cukup tinggi, dan belum tersedia di semua fasilitas kesehatan, terutama di daerah dengan akses layanan kesehatan yang terbatas. Kondisi tersebut menyebabkan banyak pasien baru diketahui menderita penyakit jantung ketika kondisinya sudah semakin parah sehingga penanganannya menjadi lebih sulit.

Di sisi lain, terdapat beberapa data klinis dasar seperti usia, tekanan darah, kadar kolesterol, hasil elektrokardiogram (EKG), serta respons tubuh terhadap aktivitas fisik yang dapat diperoleh melalui pemeriksaan kesehatan rutin dengan biaya yang relatif terjangkau. Seiring berkembangnya teknologi, khususnya di bidang Machine Learning, data-data tersebut dapat dimanfaatkan untuk membangun sistem yang mampu memprediksi risiko penyakit jantung secara otomatis. Sistem prediksi ini diharapkan dapat memberikan hasil yang cepat, konsisten, dan membantu tenaga medis dalam melakukan skrining awal tanpa harus menggunakan prosedur yang bersifat invasif.

Berdasarkan kondisi tersebut, penelitian ini bertujuan membangun model klasifikasi Machine Learning yang mampu memprediksi apakah seseorang berisiko mengalami penyakit jantung berdasarkan data klinis dasar, seperti usia, jenis kelamin, tekanan darah, kadar kolesterol, hasil EKG saat istirahat, detak jantung maksimum, serta gejala yang muncul saat aktivitas fisik, seperti angina dan ST depression. Permasalahan ini termasuk ke dalam klasifikasi biner (binary classification), yaitu mengelompokkan data ke dalam dua kelas, yaitu berisiko dan tidak berisiko, berdasarkan pola yang dipelajari dari data.

Sebagai bagian dari Capstone Project Ujian Akhir Semester Mata Kuliah Pembelajaran Mesin, penelitian ini menerapkan tahapan Machine Learning secara end-to-end menggunakan metodologi CRISP-DM (Cross-Industry Standard Process for Data Mining). Tahapan tersebut meliputi pengumpulan data, eksplorasi data, praproses, pembangunan model, evaluasi model, hingga deployment. Melalui proyek ini diharapkan dapat dihasilkan sebuah prototype aplikasi yang dapat digunakan untuk melakukan prediksi risiko penyakit

jantung serta menunjukkan penerapan Machine Learning dalam menyelesaikan permasalahan yang berkaitan dengan bidang kesehatan

1.2 Tujuan Bisnis/Analisis dan Metrik Kesuksesan

Tujuan dari proyek ini adalah membangun sebuah alat bantu skrining awal (decision support tool) yang dapat digunakan untuk memperkirakan risiko penyakit jantung secara cepat, mudah, dan dengan biaya yang lebih rendah. Alat ini diharapkan dapat membantu tenaga medis maupun masyarakat dalam melakukan deteksi awal sebelum menjalani pemeriksaan lanjutan yang lebih kompleks, seperti angiografi koroner.

Untuk mencapai tujuan tersebut, proyek ini memiliki beberapa tujuan analisis, yaitu sebagai berikut.

- Membangun pipeline Machine Learning secara end-to-end menggunakan metodologi CRISP-DM.
- Membandingkan performa tiga algoritma klasifikasi, yaitu Random Forest, XGBoost, dan Support Vector Machine (SVM).
- Melakukan tuning hyperparameter untuk memperoleh model dengan performa terbaik serta mengevaluasi model menggunakan metrik Accuracy, Precision, Recall, F1-Score, dan ROC-AUC.
- Menginterpretasikan hasil model menggunakan Feature Importance dan SHAP agar faktor-faktor yang memengaruhi prediksi dapat dipahami dengan lebih mudah, termasuk oleh pengguna non-teknis.
- Mendeploy model terbaik ke dalam aplikasi web interaktif menggunakan Streamlit sehingga dapat digunakan untuk melakukan prediksi secara langsung.

Metrik kesuksesan pada proyek ini ditentukan berdasarkan kemampuan model dalam mencapai nilai F1-Score di atas 0,85 pada data uji. Selain itu, model terbaik harus berhasil diimplementasikan ke dalam aplikasi Streamlit yang dapat berjalan dengan baik dan mudah digunakan oleh pengguna.

1.3 Sumber dan Dokumentasi Dataset

Dataset yang digunakan dalam proyek ini adalah Heart Failure Prediction Dataset yang dipublikasikan oleh fedesoriano melalui platform Kaggle. Dataset ini merupakan hasil penggabungan dari lima dataset penyakit jantung yang telah banyak digunakan dalam penelitian, yaitu Cleveland Dataset (303 data), Hungarian Dataset (294 data), Switzerland Dataset (123 data), Long Beach VA Dataset (200 data), dan Stalog (Heart) Dataset (270 data). Seluruh dataset tersebut telah dikurasi, dibersihkan, serta disesuaikan strukturnya sehingga menjadi satu dataset yang lebih lengkap dan representatif.

Setelah proses pembersihan data, seperti penghapusan data duplikat dan penyelarasan fitur, dataset akhir berisi 918 data pasien unik dengan 11 fitur klinis sebagai variabel independen dan 1 kolom target (HeartDisease) sebagai variabel dependen. Dataset ini banyak digunakan sebagai acuan dalam penelitian klasifikasi penyakit jantung karena memiliki jumlah data yang cukup dan fitur-fitur yang relevan untuk proses pemodelan Machine Learning.


Link sumber dataset: <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

- Platform: Kaggle (platform publik)
- Lisensi: Open Database License (ODbL)/CC, sehingga dapat digunakan untuk keperluan akademik dengan tetap mencantumkan sumber.
- Jumlah data: 918 data pasien.
- Jumlah fitur: 11 fitur input (variabel independen) dan 1 kolom target (HeartDisease).
- Format file: CSV (Comma-Separated Values), disimpan pada folder data/raw/heart.csv

Penjelasan mengenai setiap fitur yang terdapat pada dataset disajikan pada tabel berikut:

No	Fitur	Tipe Data	Keterangan
1	Age	Numerik (Integer)	Usia pasien saat pemeriksaan (tahun)
2	Sex	Kategorikal (String)	Jenis kelamin pasien [M: Laki-laki, F: Perempuan]
3	ChestPainType	Kategorikal (String)	Tipe nyeri dada [TA: Typical Angina, ATA: Atypical Angina, NAP: Non-Anginal Pain, ASY: Asymptomatic]
4	RestingBP	Numerik (Integer)	Tekanan darah istirahat pasien (mm Hg)
5	Cholesterol	Numerik (Integer)	Kadar kolesterol serum total pasien (mg/dl)
6	FastingBS	Kategorikal (Biner)	Gula darah puasa > 120 mg/dl [1: Ya, 0: Tidak]
7	RestingECG	Kategorikal (String)	Hasil elektrokardiogram istirahat [Normal, ST: kelainan gelombang ST-T, LVH: hipertrofi ventrikel kiri]
8	MaxHR	Numerik (Integer)	Detak jantung maksimal yang dicapai pasien (60 - 202)

9	ExerciseAngina	Kategorikal (String)	Mengalami nyeri dada akibat aktivitas/olahraga [Y: Ya, N: Tidak]
10	Oldpeak	Numerik (Float)	Depresi segmen ST yang diinduksi oleh latihan relatif terhadap istirahat
11	ST_Slope	Kategorikal (String)	Kemiringan puncak segmen ST latihan [Up: Naik, Flat: Datar, Down: Menurun]
12	HeartDisease	Target (Biner)	Status akhir risiko penyakit jantung [1: Berisiko, 0: Normal]



1.4 Statistik Deskriptif Awal

Ukuran dataset yang digunakan adalah 918 baris dan 12 kolom, yang terdiri dari 11 fitur input dan 1 kolom target (HeartDisease). Berdasarkan hasil pemeriksaan awal, dataset tidak memiliki missing value secara eksplisit maupun data duplikat. Statistik deskriptif untuk setiap fitur numerik diperoleh dari data mentah sebelum dilakukan tahap praproses dan disajikan pada tabel berikut.


Fitur	Mean	Std Dev	Min	Median	Max
Age	53.5	132.4	198.8	136.8	0.90
RestingBP	± 9.4	± 18.5	± 109.4	± 25.5	± 1.07
Cholesterol	28	0 (Anomali)	0 (Anomali)	60	-2.6
MaxHR	54.0	130.0	223.0	138.0	0.60
Oldpeak	77	200	603	202	6.2

Catatan: Pada fitur RestingBP dan Cholesterol ditemukan nilai 0, yang secara medis tidak mungkin terjadi. Oleh karena itu, nilai tersebut dianggap sebagai missing value implisit dan akan ditangani pada tahap Data Preparation.

Untuk fitur kategorikal, distribusi data menunjukkan bahwa variabel Sex didominasi oleh kategori M (Male) sebanyak 725 data atau sekitar 79%. Variabel ChestPainType paling banyak memiliki nilai ASY sebanyak 496 data atau 54%. Pada variabel

RestingECG, kategori yang paling sering muncul adalah Normal sebanyak 552 data atau sekitar 60%, sedangkan ExerciseAngina didominasi oleh kategori N (No) sebanyak 547 data atau 60%. Selain itu, variabel ST_Slope paling banyak memiliki nilai Flat sebanyak 460 data atau sekitar 50%. Sementara itu, distribusi target HeartDisease menunjukkan bahwa sekitar 55,3% data termasuk ke dalam kelas berisiko mengalami penyakit jantung. Berdasarkan hasil eksplorasi data, diperoleh beberapa temuan penting sebagai berikut.

1. Karakteristik usia pasien. Rata-rata usia pasien berada pada kisaran 53,5 tahun, sehingga dapat disimpulkan bahwa sebagian besar data berasal dari kelompok usia paruh baya hingga lanjut usia yang memiliki risiko penyakit jantung lebih tinggi.
2. Anomali pada RestingBP. Ditemukan satu data dengan nilai RestingBP = 0 mmHg. Nilai tersebut tidak mungkin terjadi pada kondisi pasien yang masih hidup sehingga dianggap sebagai kesalahan pencatatan data dan perlu diperbaiki pada tahap praproses.
3. Anomali pada Cholesterol. Terdapat 172 data dengan nilai Cholesterol = 0 mg/dL. Nilai tersebut tidak realistis secara medis sehingga diperlakukan sebagai missing value implisit. Pada tahap Data Preparation, nilai tersebut akan diganti menggunakan metode median imputation agar tidak memengaruhi proses pelatihan model.
4. Sebaran MaxHR. Nilai MaxHR berada pada rentang 60–202 bpm dengan rata-rata sekitar 136,8 bpm. Fitur ini menjadi salah satu indikator yang akan dianalisis lebih lanjut karena berkaitan dengan kemampuan jantung saat melakukan aktivitas fisik.



BAB II

METODOLOGI (CRISP-DM)

2.1 Business Understanding

Permasalahan yang diangkat dalam proyek ini adalah keterlambatan deteksi risiko penyakit jantung yang masih sering terjadi akibat proses pemeriksaan lanjutan yang membutuhkan biaya cukup besar dan tidak selalu tersedia di semua fasilitas kesehatan. Selain itu, akses terhadap dokter spesialis jantung juga masih terbatas, terutama di fasilitas kesehatan tingkat pertama. Kondisi tersebut menyebabkan sebagian pasien baru mengetahui penyakitnya ketika kondisinya sudah semakin serius.

Berdasarkan permasalahan tersebut, proyek ini bertujuan membangun model klasifikasi Machine Learning yang dapat memprediksi risiko penyakit jantung berdasarkan 11 indikator klinis non-invasif yang dapat diperoleh melalui pemeriksaan kesehatan rutin. Model yang dihasilkan diharapkan dapat membantu proses skrining awal sehingga tenaga medis memiliki gambaran awal mengenai tingkat risiko pasien sebelum dilakukan pemeriksaan lanjutan.

Keberhasilan proyek ini diukur berdasarkan performa model pada data uji dengan target F1-Score minimal 0,85 dan ROC-AUC minimal 0,85. Kedua metrik tersebut dipilih karena mampu memberikan gambaran keseimbangan antara Precision dan Recall, sehingga model tidak hanya menghasilkan prediksi yang akurat, tetapi juga mampu meminimalkan kesalahan prediksi, terutama False Negative, yaitu kondisi ketika pasien yang sebenarnya berisiko justru diprediksi tidak berisiko. Selain itu, proyek ini juga menargetkan implementasi model ke dalam aplikasi web menggunakan Streamlit sehingga hasil prediksi dapat digunakan secara langsung melalui antarmuka yang mudah dipahami oleh pengguna.

Penjelasan lebih rinci mengenai latar belakang, tujuan, dan rumusan masalah telah dijelaskan pada Bab I.

2.2 Data Understanding (Exploratory Data Analysis)

Tahap eksplorasi dilakukan terhadap dataset yang berisi 918 data pasien dengan 12 kolom, yang terdiri dari 11 fitur dan 1 kolom target (HeartDisease). Berdasarkan hasil pemeriksaan awal, dataset tidak memiliki missing value secara eksplisit maupun data duplikat. Namun, ditemukan 172 data dengan nilai Cholesterol = 0 dan 1 data dengan nilai RestingBP = 0. Nilai tersebut tidak valid secara medis sehingga dianggap sebagai missing value implisit dan akan ditangani pada tahap Data Preparation.

Selain itu, distribusi data pada variabel target menunjukkan bahwa 55,3% data termasuk ke dalam kelas Heart Disease, sedangkan 44,7% sisanya termasuk ke dalam kelas Normal.

Perbedaan proporsi kedua kelas tidak terlalu besar sehingga dataset masih dapat digunakan untuk proses pelatihan model klasifikasi.


Analisis lebih lanjut mengenai kualitas data, distribusi setiap fitur (analisis univariat), serta hubungan antarfitur dan hubungannya dengan variabel target (analisis multivariat) dijelaskan pada subbab berikutnya.

2.2.1 Analisis Kualitas Data

Pemeriksaan kualitas data dilakukan untuk memastikan data yang digunakan sudah layak sebelum masuk ke tahap pemodelan. Pemeriksaan ini meliputi *missing value*, data duplikat, *outlier*, serta *inconsistency*, yaitu data yang nilainya tidak sesuai dengan kondisi medis.

Aspek	Temuan	Keterangan
Missing Values	0 (tidak ada NaN eksplisit)	Seluruh 918 baris terisi penuh di 12 kolom
Data Duplikat	0 baris	Tidak ditemukan baris yang identik persis
Outlier (metode IQR)	Cholesterol: 19.9%, RestingBP: 3.1%, Oldpeak: 1.7%, MaxHR: 0.2%, Age: 0%	Dihitung dengan batas $Q1 - 1.5 * IQR$ s.d. $Q3 + 1.5 * IQR$
Inconsistency (nilai tidak wajar klinis)	Cholesterol=0 pada 172 baris (18.7%); RestingBP=0 pada 1 baris	Mustahil secara medis — diperlakukan sebagai hidden missing value, bukan outlier biasa


Berdasarkan hasil pemeriksaan tersebut, ditemukan bahwa dataset tidak memiliki missing value maupun data duplikat. Namun, terdapat beberapa nilai yang tidak valid secara medis, yaitu Cholesterol = 0 pada 172 data dan RestingBP = 0 pada 1 data. Nilai tersebut tidak diperlakukan sebagai outlier biasa, tetapi sebagai hidden missing value karena kemungkinan berasal dari data yang tidak tercatat atau kesalahan input. Oleh karena itu, kedua kasus tersebut ditangani menggunakan metode imputasi pada tahap Data Preparation, sedangkan outlier lainnya ditangani secara terpisah menggunakan metode Interquartile Range (IQR).



2.2.2 Analisis Univariat

Analisis univariat dilakukan untuk melihat distribusi setiap fitur secara terpisah. Pada penelitian ini, fitur numerik divisualisasikan menggunakan histogram,

sedangkan fitur kategorikal ditampilkan menggunakan bar chart. Analisis ini bertujuan untuk mengetahui pola persebaran data, nilai yang paling sering muncul, serta mendeteksi adanya nilai yang tidak wajar pada setiap fitur.




Gambar 1. Distribusi (histogram) enam fitur numerik utama.

Berdasarkan histogram, fitur Age memiliki distribusi yang mendekati normal dengan sebagian besar data berada pada rentang usia 50–60 tahun. Hal ini menunjukkan bahwa mayoritas pasien dalam dataset merupakan kelompok usia paruh baya hingga lanjut usia.

Pada fitur Cholesterol, terlihat adanya lonjakan jumlah data pada nilai 0, yang menunjukkan adanya nilai yang tidak valid secara medis. Temuan ini sesuai dengan hasil pemeriksaan kualitas data sebelumnya sehingga nilai tersebut akan ditangani pada tahap Data Preparation.


Sementara itu, fitur Oldpeak dan FastingBS memiliki distribusi yang cenderung miring ke kanan (right-skewed). Kondisi ini masih tergolong wajar karena sebagian besar data berada pada nilai rendah, sedangkan hanya sedikit data yang memiliki nilai tinggi.

BUKTI:




2.2.3 Analisis Multivariat

Analisis multivariat dilakukan untuk melihat hubungan antarfitur serta hubungan setiap fitur dengan variabel target (HeartDisease). Pada penelitian ini, analisis dilakukan menggunakan correlation heatmap, boxplot berdasarkan kelas target, dan pairplot. Tujuannya adalah untuk mengetahui tingkat korelasi antarfitur, melihat perbedaan distribusi data pada setiap kelas, serta mendeteksi pola yang dapat dimanfaatkan dalam proses pemodelan.



Gambar 2. Heatmap korelasi antar fitur numerik (analisis multivariat).



Gambar 3. Boxplot fitur numerik terhadap target - mengungkap pola & outlier per kelas.

Berdasarkan hasil correlation heatmap, tidak ditemukan pasangan fitur numerik yang memiliki nilai korelasi sangat tinggi (lebih dari 0,8). Hal ini menunjukkan bahwa tidak terdapat masalah multikolinearitas yang signifikan sehingga seluruh fitur numerik dapat digunakan dalam proses pelatihan model tanpa perlu dilakukan reduksi dimensi, seperti Principal Component Analysis (PCA).

Selain itu, hasil boxplot menunjukkan adanya perbedaan karakteristik antara pasien yang terdiagnosis Heart Disease dan pasien Normal. Pasien yang termasuk dalam kelas Heart Disease cenderung memiliki nilai MaxHR yang lebih rendah serta nilai Oldpeak yang lebih tinggi dibandingkan pasien normal. Perbedaan tersebut menunjukkan bahwa kedua fitur memiliki pengaruh terhadap proses klasifikasi penyakit jantung.


2.2.4 Visualisasi 5 Insight Kunci

Berdasarkan hasil eksplorasi data, diperoleh beberapa temuan penting yang menjadi dasar dalam proses Data Preparation dan pembangunan model Machine Learning.


1. Distribusi kelas target relatif seimbang. Data terdiri dari 55,3% pasien Heart Disease dan 44,7% pasien Normal, sehingga evaluasi model tidak hanya menggunakan Accuracy, tetapi juga mempertimbangkan F1-Score agar performa model lebih representatif.
2. Ditemukan data yang tidak valid secara medis. Terdapat 172 data dengan nilai Cholesterol = 0 dan 1 data dengan nilai RestingBP = 0. Nilai tersebut diperlakukan sebagai hidden missing value dan ditangani menggunakan metode imputasi pada tahap Data Preparation.
3. Fitur Oldpeak dan MaxHR memiliki hubungan paling kuat dengan target. Hasil analisis menunjukkan bahwa Oldpeak memiliki korelasi positif sekitar

0,40, sedangkan MaxHR memiliki korelasi negatif sekitar -0,40 terhadap variabel HeartDisease. Kedua fitur ini menjadi salah satu indikator penting dalam proses prediksi.

4. Fitur kategorikal ST_Slope dan ChestPainType memberikan informasi yang cukup jelas terhadap kelas target. Pasien dengan kategori ST_Slope = Flat dan ChestPainType = ASY (Asymptomatic) memiliki proporsi penyakit jantung yang lebih tinggi dibandingkan kategori lainnya.
5. Tidak ditemukan multikolinearitas yang tinggi antarfitur numerik. Seluruh fitur numerik memiliki nilai korelasi di bawah 0,8, sehingga seluruh fitur dapat digunakan bersama dalam proses pemodelan tanpa perlu dilakukan reduksi dimensi.




Gambar 4. Distribusi kelas target HeartDisease (Insight 1).



Gambar 5. Distribusi fitur kategorikal terhadap target (Insight 4).

BUKTI:



2.3 Data Preparation (Feature Engineering & Preprocessing)

Berdasarkan hasil analisis pada tahap Data Understanding, dilakukan beberapa proses Data Preparation untuk meningkatkan kualitas data sebelum digunakan dalam proses pelatihan model. Setiap tahapan praproses dilakukan sesuai dengan karakteristik data yang ditemukan pada tahap eksplorasi dan disertai alasan pemilihan metode yang digunakan.

Teknik	Implementasi	Justifikasi
Data Cleaning	Imputasi median per kelas target pada Cholesterol=0 dan RestingBP=0	Median dipilih (bukan mean) karena tahan terhadap outlier; imputasi per kelas (bukan global) agar tidak mengaburkan perbedaan pola antar kelas; baris tidak dihapus karena akan menghilangkan 18.7% data (informasi berharga)

Feature Engineering	Menambahkan AgeGroup (kelompok usia) dan HR_Reserve (220-Age dikurangi MaxHR)	AgeGroup mempermudah interpretasi pola risiko per rentang usia; HR_Reserve merepresentasikan cadangan kapasitas jantung, indikator klinis yang relevan namun tidak tersedia langsung di data mentah
Encoding	One-Hot Encoding pada 5 fitur kategorikal (Sex, ChestPainType, RestingECG, ExerciseAngina, ST_Slope)	Fitur kategorikal bersifat nominal (tanpa urutan), sehingga One-Hot Encoding lebih tepat dibanding Label Encoding yang dapat menyiratkan urutan palsu
Scaling	StandardScaler pada 6 fitur numerik	Menyamakan skala antar fitur (mis. Cholesterol berskala ratusan vs Oldpeak berskala satuan); krusial khususnya untuk SVM yang sensitif terhadap skala fitur
Feature Selection	Seluruh fitur numerik dipertahankan (tidak ada PCA/reduksi)	Tidak ditemukan multikolinearitas ekstrem (korelasi > 0.8) pada tahap analisis multivariat, sehingga reduksi dimensi tidak diperlukan

Seluruh tahapan praproses diimplementasikan menggunakan Pipeline dari scikit-learn yang menggabungkan ColumnTransformer dan Estimator. Dengan menggunakan pipeline, proses praproses yang diterapkan pada data pelatihan akan dilakukan secara konsisten pada data pengujian maupun saat proses prediksi di aplikasi deployment. Selain itu, penggunaan pipeline juga membantu mencegah terjadinya data leakage, sehingga hasil evaluasi model menjadi lebih valid dan dapat dipercaya.

2.4 Pembagian Dataset (Train-Validation-Test Split)

Subset	Proporsi	Jumlah Baris	Fungsi
Train	70%	642 baris	Melatih parameter model
Validation	10%	92 baris	Memilih model terbaik & tuning hyperparameter
Test	20%	184 baris	Evaluasi akhir performa model (tidak pernah dilihat model sebelumnya)

Dataset dibagi menjadi tiga bagian menggunakan stratified split (mempertahankan proporsi kelas target di setiap subset), dengan komposisi sebagai berikut:

Stratifikasi dipilih agar proporsi kelas HeartDisease (55.3% vs 44.7%) tetap konsisten di ketiga subset, sehingga evaluasi model tidak bias akibat perbedaan distribusi kelas antar subset.


2.5 Modelling

Pada tahap Modelling, digunakan tiga algoritma klasifikasi, yaitu Random Forest, XGBoost, dan Support Vector Machine (SVM). Ketiga algoritma tersebut dipilih karena mewakili tiga pendekatan yang berbeda dalam Machine Learning, yaitu bagging, boosting, dan margin-based classification. Selain itu, ketiganya dikenal memiliki performa yang baik dalam mengolah data tabular dengan jumlah data sedang, seperti dataset yang digunakan pada penelitian ini.

Karakteristik masing-masing algoritma adalah sebagai berikut:

- Random Forest merupakan algoritma ensemble berbasis bagging yang menggabungkan banyak decision tree. Algoritma ini mampu mengurangi risiko overfitting serta dapat memberikan informasi mengenai tingkat kepentingan setiap fitur (feature importance).
- XGBoost merupakan algoritma ensemble berbasis gradient boosting yang membangun decision tree secara bertahap. Setiap pohon baru dibuat untuk memperbaiki kesalahan prediksi dari pohon sebelumnya sehingga sering menghasilkan performa yang tinggi pada data tabular.
- Support Vector Machine (SVM) merupakan algoritma yang bekerja dengan mencari hyperplane terbaik untuk memisahkan dua kelas data. Algoritma ini cocok digunakan pada data dengan jumlah fitur sedang dan mampu menghasilkan klasifikasi yang baik ketika batas antar kelas cukup jelas.

Untuk memperoleh performa terbaik, setiap algoritma dilakukan proses hyperparameter tuning menggunakan GridSearchCV dengan 5-fold cross-validation. Proses optimasi menggunakan F1-Score sebagai metrik utama karena distribusi kelas pada dataset sedikit tidak seimbang. Parameter yang diuji meliputi jumlah estimator dan kedalaman pohon pada Random Forest, jumlah estimator, learning rate, dan subsample pada XGBoost, serta parameter C, kernel, dan gamma pada Support Vector Machine (SVM).




2.6 Evaluation

Pada tahap Evaluation, ketiga model yang telah dibangun, yaitu Random Forest, XGBoost, dan Support Vector Machine (SVM), dievaluasi menggunakan data uji yang berjumlah 184 data. Data uji ini tidak digunakan pada proses pelatihan maupun hyperparameter tuning, sehingga hasil evaluasi dapat memberikan gambaran yang lebih objektif mengenai kemampuan model dalam melakukan prediksi.

Berdasarkan hasil pengujian, model XGBoost memperoleh performa terbaik dibandingkan dua model lainnya. Model ini menghasilkan F1-Score sebesar 0,921 dan ROC-AUC sebesar 0,947, sehingga telah memenuhi target keberhasilan proyek, yaitu F1-Score minimal 0,85.

Evaluasi model dilakukan menggunakan beberapa metrik, yaitu Accuracy, Precision, Recall, F1-Score, dan ROC-AUC. Selain itu, hasil evaluasi juga divisualisasikan menggunakan Confusion Matrix dan ROC Curve untuk melihat kemampuan model dalam membedakan kelas Heart Disease dan Normal. Agar hasil prediksi lebih mudah dipahami, dilakukan pula interpretasi model menggunakan Feature Importance dan SHAP untuk mengetahui fitur-fitur yang paling berpengaruh terhadap hasil prediksi.

Hasil evaluasi secara lengkap, termasuk tabel perbandingan performa model dan visualisasi pendukung, disajikan pada Bab III.



2.7 Deployment

Setelah proses pelatihan dan evaluasi selesai, model dengan performa terbaik disimpan dalam format pickle (.pkl) beserta pipeline preprocessing yang digunakan. Penyimpanan model dan pipeline dilakukan agar proses praproses data saat prediksi tetap sama dengan proses yang digunakan pada saat pelatihan model, sehingga hasil prediksi menjadi lebih konsisten.

Model tersebut kemudian diintegrasikan ke dalam aplikasi web berbasis Streamlit sebagai media untuk melakukan prediksi risiko penyakit jantung secara interaktif. Aplikasi yang dikembangkan terdiri dari lima halaman utama, yaitu Dashboard EDA untuk menampilkan hasil eksplorasi data, Model Demo untuk melakukan prediksi secara langsung, Evaluasi Model yang berisi hasil pengujian performa model, Interpretasi Hasil yang menampilkan penjelasan faktor-faktor yang memengaruhi prediksi menggunakan Feature Importance dan SHAP, serta Dokumentasi yang berisi informasi mengenai proyek secara keseluruhan.

BAB III

HASIL DAN ANALISIS

3.1 Hasil Tuning Hyperparameter



Pada tahap ini, ketiga model, yaitu Random Forest, XGBoost, dan Support Vector Machine (SVM), dilakukan proses hyperparameter tuning menggunakan GridSearchCV dengan 5-fold cross-validation. Proses optimasi menggunakan F1-Score sebagai metrik utama karena distribusi kelas pada dataset sedikit tidak seimbang. Parameter yang diuji meliputi `n_estimators` dan `max_depth` untuk model berbasis decision tree (Random Forest dan XGBoost), serta `C` dan `kernel` untuk model SVM. Hasil kombinasi hyperparameter terbaik dari masing-masing model disajikan pada tabel berikut.

Model	Best Params	Mean CV F1 (5-fold)	Val F1
Random Forest	<code>n_estimators=300, max_depth=5, min_samples_leaf=2</code>	0.878	0.832
XGBoost	<code>n_estimators=100, max_depth=3, lr=0.1, subsample=0.8</code>	0.887	0.876
SVM	<code>C=1, kernel=rbf, gamma=auto</code>	0.878	0.843

Berdasarkan hasil cross-validation, ketiga model menunjukkan selisih yang relatif kecil antara Mean CV F1-Score dan Validation F1-Score. Random Forest memiliki selisih sebesar 0,046, SVM sebesar 0,035, sedangkan XGBoost sebesar 0,011. Selisih yang kecil tersebut menunjukkan bahwa ketiga model tidak mengalami overfitting yang signifikan selama proses hyperparameter tuning.

Di antara ketiga model, XGBoost memperoleh hasil terbaik dengan Mean CV F1-Score sebesar 0,887 dan Validation F1-Score sebesar 0,876. Selain memiliki nilai F1-Score yang paling tinggi, XGBoost juga memiliki selisih performa yang paling kecil antara data pelatihan dan data validasi. Hal ini menunjukkan bahwa model mampu melakukan generalisasi dengan baik terhadap data yang belum pernah dilihat sebelumnya.

Berdasarkan hasil tersebut, XGBoost dipilih sebagai model terbaik untuk dilanjutkan ke tahap evaluasi menggunakan data uji (test set) yang tidak digunakan selama proses pelatihan maupun hyperparameter tuning.



3.2 Perbandingan Performa Model (Data Uji)


Tabel Perbandingan Performa Model (Test Set)

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
XGBoost	0.913	0.93	0.9118	0.9208	0.9473
RandomForest	0.8587	0.8585	0.8922	0.875	0.9319
SVM	0.8533	0.8571	0.8824	0.8696	0.9321


Gambar 4. Tabel perbandingan metrik evaluasi pada data uji.

Berdasarkan hasil evaluasi pada data uji, XGBoost menjadi model dengan performa terbaik dibandingkan Random Forest dan Support Vector Machine (SVM). Model ini memperoleh F1-Score sebesar 0,921 dan ROC-AUC sebesar 0,947, sehingga telah melampaui target keberhasilan proyek, yaitu F1-Score minimal 0,85.

Hasil tersebut menunjukkan bahwa XGBoost mampu memberikan performa yang baik dalam mengklasifikasikan risiko penyakit jantung pada dataset yang digunakan. Kemampuan XGBoost dalam mempelajari hubungan yang kompleks antarfitur membuat model ini lebih efektif untuk menangani data tabular seperti Heart Failure Prediction Dataset, sehingga menghasilkan prediksi yang lebih akurat dibandingkan model lainnya.




Gambar 5. Confusion Matrix ketiga model pada data uji.




Gambar 6. ROC Curve perbandingan ketiga model.

3.3 Interpretasi Model Terbaik (XGBoost)



Gambar 7. Feature Importance model XGBoost.



Gambar 8. SHAP Summary Plot model XGBoost.

Berdasarkan hasil analisis Feature Importance dan SHAP, diketahui bahwa fitur ST_Slope, ChestPainType (terutama kategori ASY atau asymptomatic), Oldpeak, dan MaxHR merupakan fitur yang paling berpengaruh terhadap hasil prediksi model.


Hasil analisis menunjukkan bahwa nilai Oldpeak yang lebih tinggi cenderung meningkatkan peluang pasien diprediksi berada pada kelas Heart Disease. Sebaliknya, nilai MaxHR yang lebih tinggi cenderung mengarahkan prediksi ke kelas Normal. Selain itu, fitur ST_Slope dan ChestPainType juga memberikan kontribusi yang cukup besar dalam membedakan pasien yang berisiko dan yang tidak berisiko mengalami penyakit jantung.








Temuan tersebut sesuai dengan karakteristik klinis yang dijelaskan dalam berbagai penelitian mengenai penyakit jantung. Oleh karena itu, hasil interpretasi ini tidak hanya menunjukkan bahwa model memiliki performa yang baik secara statistik, tetapi juga menghasilkan prediksi yang masih sesuai dengan pengetahuan di bidang medis.






3.4 Aplikasi Deployment

Model terbaik telah diintegrasikan ke dalam aplikasi berbasis Streamlit yang memiliki lima halaman utama. Halaman pertama adalah Dashboard EDA yang digunakan untuk menampilkan hasil eksplorasi data. Halaman kedua adalah Model Demo yang memungkinkan pengguna melakukan prediksi risiko penyakit jantung secara langsung melalui form input. Halaman ketiga, yaitu Evaluasi Model, menyajikan perbandingan performa ketiga algoritma yang digunakan. Halaman keempat adalah Interpretasi Hasil yang menampilkan Feature Importance dan SHAP untuk menjelaskan faktor-faktor yang memengaruhi hasil prediksi. Halaman terakhir adalah Dokumentasi yang berisi informasi mengenai proyek dan tahapan yang dilakukan. Source code aplikasi tersimpan pada file `app/app.py` dan dapat dijalankan secara lokal maupun di-deploy menggunakan Streamlit Community Cloud.

Berikut merupakan tampilan antarmuka aplikasi Streamlit yang telah berhasil diimplementasikan.







BAB IV

KESIMPULAN DAN REKOMENDASI

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat diambil beberapa kesimpulan sebagai berikut.

- Pipeline Machine Learning berhasil dibangun secara end-to-end dengan mengikuti tahapan metodologi CRISP-DM, mulai dari Business Understanding, Data Understanding, Data Preparation, Modelling, Evaluation, hingga Deployment.
- Berdasarkan hasil evaluasi, model XGBoost memberikan performa terbaik dibandingkan model lainnya dengan nilai F1-Score sebesar 0,921 dan ROC-AUC sebesar 0,947. Hasil tersebut telah melampaui target keberhasilan proyek yang telah ditetapkan.
- Hasil interpretasi model menunjukkan bahwa fitur ST_Slope, ChestPainType, Oldpeak, dan MaxHR merupakan fitur yang paling berpengaruh dalam memprediksi risiko penyakit jantung. Temuan ini juga sesuai dengan karakteristik klinis yang dijelaskan dalam berbagai penelitian mengenai penyakit jantung.
- Model terbaik berhasil diimplementasikan ke dalam aplikasi berbasis Streamlit yang dapat digunakan sebagai alat bantu skrining awal. Aplikasi ini mampu melakukan prediksi secara cepat melalui antarmuka yang sederhana sehingga mudah digunakan oleh pengguna..

4.2 Keterbatasan Penelitian

Beberapa keterbatasan dalam penelitian ini adalah sebagai berikut.

- Dataset yang digunakan belum memiliki beberapa fitur klinis, seperti SpO2 (kadar oksigen dalam darah) dan tekanan darah diastolik, yang berpotensi memberikan informasi tambahan dalam proses prediksi.
- Dataset merupakan hasil penggabungan data dari beberapa rumah sakit dan negara yang berbeda sehingga karakteristik pasien mungkin belum sepenuhnya mewakili kondisi populasi saat ini.
- Model yang dibangun hanya menggunakan data tabular dan belum memanfaatkan data medis lain, seperti sinyal EKG mentah atau citra jantung, yang berpotensi meningkatkan performa model.

4.3 Rekomendasi

Beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya adalah sebagai berikut.

- Menambahkan data dari sumber lain yang memiliki fitur SpO2 dan tekanan darah diastolik agar informasi yang digunakan dalam proses prediksi menjadi lebih lengkap.
- Mencoba metode ensemble stacking dengan menggabungkan algoritma Random Forest, XGBoost, dan Support Vector Machine (SVM) untuk melihat kemungkinan peningkatan performa model.
- Menambahkan fitur logging dan monitoring performa model apabila aplikasi akan digunakan pada lingkungan produksi, sehingga perubahan performa model dapat dipantau secara berkala.
- Aplikasi yang dikembangkan sebaiknya digunakan sebagai alat bantu skrining awal dan bukan sebagai pengganti diagnosis medis. Hasil prediksi tetap perlu dikonfirmasi melalui pemeriksaan dan evaluasi oleh tenaga medis.

BAB V

DOKUMENTASI DAN PRESENTASI

5.1 Link GitHub

<https://github.com/lailymuthia/lailymuthia-A11.2024.15618-heart-disease-prediction-UAS.git>

5.2 Link Streamlit (Demo)

<https://lailymuthia-a11202415618-heart-disease-prediction-uas-mw2gumky.streamlit.app>

5.3 Link YouTube (Presentasi)

<https://youtu.be/2Q8nuH0KRiQ>

5.4 Link Laporan PDF

https://drive.google.com/drive/folders/1I7Wa9iL-trKqU0hzWEqkTdEZk_WKI_Yg?usp=drive_link

5.5 Link Repositori Mingguan

<https://github.com/lailymuthia/Materi-Pembelajaran-Mesin-Lengkap.git>

REFERENSI

- Fedesoriano. (2021). Heart Failure Prediction Dataset. Kaggle.
<https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>
- Kementerian Kesehatan RI. (2022). Satu dari Tiga Kematian Disebabkan oleh Jantung, Ayo Cegah Serangan Jantung. Unit Pelayanan Kesehatan Kemenkes RI.
<https://upk.kemkes.go.id/new/satu-dari-tiga-kematian-disebabkan-oleh-jantung-ayo-cegah-serangan-jantung>
- Kementerian Kesehatan RI. (2023). Kemenkes: Penyakit Kardiovaskular Penyebab Kematian Tertinggi di Indonesia. Dinas Kesehatan Provinsi Aceh.
<https://dinkes.acehprov.go.id/detailpost/kemenkes-penyakit-kardiovaskular-penyebab-kematian-tertinggi-di-indonesia>
- Kirono, dkk. (2024). Perbandingan Algoritma Machine Learning dalam Analisis Penyebab Penyakit Gagal Jantung. JEPIN (Jurnal Edukasi dan Penelitian Informatika), 10(2).
<https://jurnal.untan.ac.id/index.php/jepin/article/view/78369>
- Kompas.com. (2022, September 28). Kemenkes: Penyakit Jantung Penyebab Kematian Tertinggi pada 2014–2019.
<https://nasional.kompas.com/read/2022/09/28/17402891/kemenkes-penyakit-jantung-penyebab-kematian-tertinggi-pada-2014-2019>
- Pusat Penelitian, Pengabdian kepada Masyarakat dan Publikasi Internasional UMA. (2025, Juni 11). SHAP Values: Making Machine Learning Models Explainable.
<https://p3mpi.uma.ac.id/2025/06/11/shap-values-making-machine-learning-models-explainable/>
- Realino, A., Nugraha, W., & Sa'adah, R. (2026). Komparasi Model Logistic Regression dan Random Forest pada Prediksi Penyakit Jantung Berdasarkan Analisis Fitur Klinis. JUKTISI (Jurnal Komputer Teknologi Informasi Sistem Komputer), 5(2), 1713–1721.
<https://doi.org/10.62712/juktisi.v5i2.1400>

- Selayanti, N., dkk. (2024). Penerapan Machine Learning Algoritma Random Forest untuk Prediksi Penyakit Jantung. Prosiding Seminar Nasional Sains Data. <https://prosiding-senada.upnjatim.ac.id/index.php/senada/article/view/376>
- Suhanda, Y., Kurniati, I., & Norma, S. (2020). Penerapan Metode CRISP-DM dengan Algoritma K-Means Clustering untuk Segmentasi Mahasiswa Berdasarkan Kualitas Akademik. *Jurnal Teknologi Informatika dan Komputer*, 6(2), 12–20. <https://doi.org/10.37012/jtik.v6i2.299>
- Wijaya, C. Y. (2022). Feature Importance — Mendapatkan Insight Melalui Machine Learning Model. *Beridata (Medium)*. <https://medium.com/beridata/feature-importance-mendapatkan-insight-melalui-machine-learning-model-2540ddc23184>